

## Task 2 - Teoría

*1. ¿Cuál es el problema del gradiente de fuga en las redes LSTM y cómo afecta la efectividad de LSTM para el pronóstico de series temporales?*

El problema del gradiente de fuga en las redes LSTM es que pueden experimentar dificultad al intentar aprender secuencias de datos a largo plazo. Las redes LSTM están diseñadas para manejar dependencias a largo plazo en los datos de series temporales, pero cuando sucede el caso de que se propagan los gradientes hacia atrás durante el proceso de entrenamiento, los gradientes tienden a disminuir exponencialmente a medida que retroceden en el tiempo. Quiere decir que los efectos de los datos pasados en el cálculo de los gradientes disminuyen rápidamente, lo que puede hacer que la red olvide información importante de las secuencias largas, limitando su capacidad para pronosticar de manera efectiva patrones a largo plazo.

Este problema de gradiente de fuga afecta la efectividad de las LSTM para el pronóstico de series temporales, por que se puede dar que la LSTM no capture adecuadamente las dependencias a largo plazo en los datos.

*2. ¿Cómo se aborda la estacionalidad en los datos de series temporales cuando se utilizan LSTM para realizar pronósticos y qué papel juega la diferenciación en el proceso?*

Para abordar la estacionalidad en los datos de series temporales al utilizar LSTM en el pronóstico, se suele aplicar un proceso de diferenciación. La estacionalidad son los patrones recurrentes que se repiten a intervalos regulares en los datos, como las fluctuaciones diarias. La diferenciación implica calcular la diferencia entre valores sucesivos en la serie temporal. Esto puede ser una diferencia de primer orden o de un orden superior si es necesario.

La diferenciación es útil porque ayuda a eliminar la componente de estacionalidad de los datos, convirtiendo la serie temporal en una serie más estacionaria en la que los patrones sean más fáciles de capturar para LSTM. La red LSTM se entrena en esta serie de tiempo diferenciada y, después de realizar pronósticos, se pueden revertir las operaciones de diferenciación para obtener pronósticos en la escala original de la serie temporal.

*3. ¿Cuál es el concepto de "tamaño de ventana" en el pronóstico de series temporales con LSTM y cómo afecta la elección del tamaño de ventana a la capacidad del modelo para capturar patrones a corto y largo plazo?*

El concepto de "tamaño de ventana" en el pronóstico de series temporales con LSTM es la cantidad de pasos de tiempo pasados que se utilizan como entrada para predecir el siguiente valor en la serie temporal. El tamaño de la ventana es una parte importante del diseño del modelo y afecta directamente la capacidad del modelo para capturar patrones a corto y largo plazo. Si el tamaño de la ventana es pequeño, el modelo solo tendrá acceso a información reciente, lo que le permitirá capturar patrones a corto plazo pero perderá información importante sobre patrones a largo plazo en los datos. Si el tamaño de la ventana es grande, el modelo tendrá acceso a una mayor cantidad de datos históricos, lo que permite capturar patrones a largo plazo en la serie temporal, pero esto también puede perjudicar un poco al introducir más ruido en los datos y hacer que el modelo sea más propenso a overfitting.